


An abstract graphic featuring a solid red rectangle in the upper left corner. A black rectangular frame is positioned to the right of the red rectangle, with its top and bottom edges extending further to the right. The text is located within the white space of this frame.

ETIQUETATGE DE COLOR I FORMA EN IMATGES DE ROBA.

Grup 74 - Intel·ligència Artificial.
22-5-2025

Alejandro Zorrilla Bejarano - 1713947

Josep Montoro Pascual - 1710404

Roger Salcedo Roquet - 1714533


ÍNDEX

1.- Introducció a la pràctica.....	3
1.1.- Metodologia.....	3
1.1.1.- Preparació de les dades.....	3
1.1.2.- Extracció de característiques.....	4
1.1.3.- Implementació dels algorismes.....	5
1.1.4.- Anàlisi qualitatiu.....	5
1.1.5.- Anàlisi quantitatiu.....	6
2.- Mètodes d'anàlisi implementats.....	7
2.1.- Anàlisi Qualitatiu.....	7
2.1.1.- Retrieval by color.....	7
2.1.2.- Retrieval by shape.....	8
2.1.3.- Retrieval combined.....	10
2.2.- Anàlisi Quantitatiu.....	12
2.2.1.- Get_shape_accuracy.....	12
2.2.2.- Get_color_accuracy.....	13
2.2.3.- Kmeans_analysis.....	13
2.2.4.- Knn_systematic_analysis.....	19
2.2.5.- Compare_find_bestK_heuristics.....	25
3.- Millores sobre Kmeans i KNN.....	28
3.1.- Millores implementades a KMeans.....	28
3.2.- Millores implementades a KNN.....	30
4.- Altres implementacions.....	31
4.1.- VisualitzarRetrievalAmbKMeans.....	31
4.2.- Mostrar_retrieval.....	31
4.3.- Resize_images.....	32
4.4.- Kmeans interactiu.....	32
4.5.- KNN interactiu.....	35
4.6.- Buscador interactiu.....	38
4.7.- Menú Principal (main).....	41
5.- Conclusió global.....	44

1.- Introducció a la pràctica

En aquesta pràctica explorem un cas real de classificació automàtica amb intel·ligència artificial de peces de roba.

Per una banda, identifiquem la forma de la peça de roba (samarreta, pantaló, xancles, etc) utilitzant l'algorisme K-Nearest Neighbors (KNN) i, d'altra banda, extraiem els colors predominants de la peça amb l'algorisme K-means.



1.1.- Metodologia

La metodologia utilitzada per a poder executar aquest projecte segueix el següent patró:

1.1.1.- Preparació de les dades


Definim tots els tipus d'imatges amb els que podem treballar els quals més tard podràs seleccionar per a fer les proves.

```
Cargando dataset...
Redimensionando imágenes...
Numero de img: 180
Numero de test_img: 851
Numero de cropped_images: 180
Numero de cropped_resized: 180
```

1.1.2- Extracció de característiques

En el cas del classificador KNN, el nostre objectiu és identificar la forma de la roba. Com que el color no és rellevant per aquest objectiu, convertim totes les imatges a escala de grisos.


Posteriorment, representem cada imatge com un vector de característiques. Aquest vector pot ser el valor de tots els píxels (representació "raw") o una versió resumida utilitzant estadístiques com la mitjana global dels píxels o la mitjana de la meitat superior i inferior ("mean_halves"). Així amb aquestes diferents estratègies podem comparar formes resultants (explicat en profunditat a la següent pàgina).



L'objectiu del KMeans és trobar els colors predominants d'una imatge. Per això, no convertim les imatges a escala de grisos, sinó que utilitzem directament els valors RGB dels píxels. A cada imatge, aplanem la matriu de píxels en un conjunt de punts en un espai tridimensional (R, G, B).

Aquesta representació permet agrupar píxels segons la seva proximitat amb KMeans. Cada clúster trobat representa un color predominant.

Amb aquesta imatge d'exemple es mostra aquest procés: a partir d'una imatge original, s'obté una versió "reduïda" amb pocs colors i es visualitza també com un núvol de punts en 3D, on s'observen les agrupacions de color.



1.1.3.- Implementació dels algorismes

Els dos algorismes principals utilitzats en aquest projecte, **KNN** i **KMeans**, tenen diferents opcions configurables que permeten analitzar els resultats al rendiment i la precisió del projecte segons l'opció que s'escull.

- **KNN:**

Per a l'algorisme KNN, que serveix per classificar la forma de les peces de roba, s'han incorporat diferents estratègies tant en la definició de la distància com en la representació de les característiques.

Tipus de distància: l'usuari pot escollir entre distància euclidiana, manhattan o cosine. Aquestes distàncies es calculen sobre vectors de característiques de les imatges i serveixen per determinar quines mostres del conjunt d'entrenament són les més similars a la imatge de test (explicades en profunditat a l'apartat 3.1)

Tipus de característiques: també es pot configurar com es representen les imatges amb característiques "raw", "mean_rgb", "mean_halves" o "grayscale_mean" (explicades en profunditat a l'apartat 3.1)

- **K-means:**

En el cas de KMeans, utilitzat per identificar els colors predominants, s'han provat diferents estratègies d'inicialització dels centroides, que afecten directament al resultat del clustering.

Tenim 5 tipus d'**inicialitzacions** que són:

First: agafa els primers K punts com a centroides.

Random: selecciona centroides aleatoris.

Custom: estratègia definida manualment.

(més tard els tipus **Kmeans++** i **pca** afegit i explicat amb detall a l'apartat 3.1)

També s'han aplicat diferents **heurístiques** per escollir el millor valor de K que son:

WCD (Within-Class Distance): mesura la compactació interna dels clústers.

BCD (Between-Class Distance): mesura la separació entre clústers.

Fisher Score: relació entre BCD i WCD, buscant màxima separació i mínima dispersió interna.

1.1.4.- Anàlisi qualitatiu

Després d'executar els algorismes amb les opcions seleccionades per l'usuari, continuem amb una representació visual dels resultats utilitzant funcions com `visualize_k_means` o `mostrar_retrieval` (apartat 4. - Altres implementacions).

Aquestes funcions fan ús dels mètodes d'anàlisi qualitatiu definits a l'apartat 2, els quals permeten ordenar les imatges en funció del percentatge de coincidència amb les etiquetes assignades (ja siguin de forma, color o les dues).

Finalment, es crea una gràfica visual que ensenya les imatges amb més percentatge de fiabilitat, tenint així un resultat visual final per a poder veure si els algorismes estan funcionant correctament o hi poden tenir alguna millora.

1.1.5.- Anàlisi quantitatiu

Per tal d'avaluar el rendiment dels algorismes en aquest apartat, hem implementat diversos mètodes d'anàlisi quantitatiu que mesuren la precisió dels resultats obtinguts.

Precisió:

Per KNN, calculem la precisió amb els diferents tipus de distàncies i característiques junt amb el temps d'execució per a trobar la combinació que dona la millor eficiència.

Per KMeans, fem el mateix amb les etiquetes de color, tenint en compte tant les imatges originals com les retallades (cropped), ja que en teoria un cop retallades ja que s'eliminen colors innecessaris que estan a les cantonades de les imatges llavors la precisió hauria d'augmentar teòricament.

Heurístiques:

Generem gràfics que mostren l'evolució de diferents heurístiques segons el valor de K , un cop tenim els resultats els analitzem per a veure quina heurística dona la millor evolució i, per tant, millors resultats:

- **WCB:** ha de disminuir a mesura que augmenta K .
- **BCD:** ha d'augmentar a mesura que augmenta K ja que els clusters són més separables.
- **Fisher:** Combina les dues anteriors i ha d'augmentar a mesura junt amb K

Personalment, hem construït el projecte en forma de menú pel qual podem escollir quins resultats en concret volem, però un cop ja tenim els resultats del tema en concret que hem escollir ja podem passar a analitzar-los tenint en compte les dades del tema escollir per a veure quines opcions donen el millor resultat final.

2.- Mètodes d'anàlisi implementats

En aquest apartat descrivim els mètodes d'anàlisi implementats per avaluar visualment i numèricament els classificadors fets amb KMeans i KNN.

2.1.- Anàlisi Qualitatiu

2.1.1.- Retrieval by color

Objectiu: Cercar imatges que continguin colors específics i ordenar-les segons la predominància d'aquests colors.

Paràmetres d'Entrada:

- Llista d'imatges.
- Etiquetes de color predites per KMeans per a cada imatge (ex: ["Red", "Blue"]).
- Colors a cercar (ex: query_colors = ["Red", "Blue"]).
- Opcional: Percentatges de cada color a la imatge (útil per ordenar resultats).
- Opcional: Opció de retornar puntuació
-

Processament:


1. Filtra les imatges que continguin almenys un dels colors cercats.
2. Si es proporcionen percentatges, ordena les imatges per la suma dels percentatges dels colors coincidents.
3. Retorna puntuació si aquesta opció està activa.

Sortida

- Imatges ordenades per rellevància (ex: major percentatge de "Red" primer).

Exemples de cas d'ús:

Cerca d'imatges retallades amb color blau



Cerca d'imatges amb color blau

Color: Blue



En els exemples analitzats, podem veure com es fa una cerca d'imatges amb peces de roba blaves. A més, s'observa clarament que les imatges retallades ofereixen millors resultats en la cerca per colors que les imatges completes. Aquesta millora es deu principalment a l'eliminació del fons durant el procés de retall, que sovint introdueix soroll i colors no rellevants per a l'anàlisi. En concret, les imatges retallades mostren un percentatge més alt de coincidència amb els colors reals de l'objecte, ja que el retall elimina les interferències del fons i permet al KMeans centrar-se exclusivament en els colors de la peça de roba. Aquest contrast és especialment evident quan comparem els resultats d'una mateixa imatge en les seves versions completa i retallada, on la versió retallada mostra una identificació més precisa dels colors predominants.

2.1.2.- Retrieval by shape

Objectiu: Recuperar imatges que coincideixin amb una forma específica (ex: "Shirts") i ordenar-les per confiança (vots del KNN).

Paràmetres d'Entrada:

- Llista d'imatges.
- Etiquetes de forma predites per KNN (ex: ["Shirts", "Dresses"]).
- Forma a cercar (ex: query_shape = "Shirts").
- Opcional: Percentatge de vots dels veïns més propers (confiança).
- Opcional: Opció de retornar puntuació

Processament:

1. Filtra les imatges l'etiqueta predita de les quals coincideixi amb query_shape.
2. Ordena les imatges pel percentatge de vots (ex: una imatge amb 90% de vots per "Shirts" apareix abans que una amb 70%).
3. Retorna puntuació si aquesta opció està activa.


Sortida

- Imatges ordenades per confiança en la predicció.


Exemples de cas d'ús:

Cerca de bosses de mà

Forma: Handbags



Cerca de bosses de mà amb imatges retallades



En aquests exemples podem veure una cerca d'imatges que siguin bosses de mà, A més, podem observar una diferència significativa entre utilitzar imatges completes i retallades per a la classificació de formes. Mentre el KMeans sí que es beneficia del retall per identificar colors, el KNN mostra problemes de precisió amb imatges retallades, ja que el procés elimina parts crítiques necessàries per reconèixer correctament les formes. Un exemple clar és quan una xancla es classifica erròniament com a bossa: en retallar la imatge, la regió de l'agafador - clau per distingir una xancla d'una bossa - desapareix, provocant aquest error de classificació. Aquest fenomen demostra que, encara que el retall pot ser útil per a l'anàlisi de colors, no és adequat per a la classificació de formes, ja que elimina informació visual essencial per a una correcta identificació. La comparativa visual entre imatges completes i retallades d'aquest mateix objecte seria una bona manera d'il·lustrar aquesta limitació.

2.1.3.- Retrieval combined

Objectiu: Cercar imatges que compleixin ambdós criteris: forma + color, i ordenar-les per un score combinat.

Paràmetres d'Entrada:

- Etiquetes de color (KMeans) i forma (KNN).
- Forma (query_shape = "Shirts") i colors (query_colors = ["Red", "Blue"]) a cercar.
- Percentatges de color i vots de forma.

Processament:


1. Filtra imatges que coincideixin amb la forma desitjada.
2. Dins d'aquestes, filtra les que continguin els colors cercats.
3. Calcula un score combinat:
4. Ordena per aquest score.

Sortida


- Imatges que són, per exemple, "Shirts" amb predomini de "Red" o "Blue".

Exemples de cas d'ús:

Shorts + Blue



Cerca de pantalons curts blaus



Cerca de pantalons curts blaus amb imatges retallades

L'anàlisi comparativa de les cerques de shorts blaus mostra resultats reveladors: mentre la cerca en imatges completes ofereix resultats satisfactoris, la versió amb imatges retallades presenta problemes significatius. Aquesta diferència confirma el que hem observat en exemples anteriors - el retall d'imatges, tot i millorar l'anàlisi de colors, resulta contraproduent per cerques que requereixen reconèixer tant la forma com el color.

El problema rau en el fet que el procés de retall elimina parts essencials de les peces que permeten identificar correctament la seva forma. En el cas dels shorts blaus, algunes imatges retallades perden les característiques distintives d'aquesta peça (com l'obertura de les cames o l'elàstic de la cintura), portant a confusions en la classificació. Això explica per què la cerca combinada de color i forma funciona millor amb les imatges completes, que conserven tota la informació visual necessària per a una identificació precisa.

2.2.- Anàlisi Quantitatiu

2.2.1.- Get_shape_accuracy

Objectiu: Aquesta funció avalua la precisió d'un model de classificació de formes (normalment obtingut mitjançant KNN) comparant les prediccions amb les etiquetes reals (ground truth).

Paràmetres d'Entrada:

- preds: Llista d'etiquetes predites pel model (ex: ['Shirt', 'Dress', 'Pants'])
- gts: Llista d'etiquetes reals en el mateix ordre
- return_errors: Flag opcional per obtenir detall d'errors (False per defecte)

Processament:

1. Inicialitza comptadors per a encerts i errors
2. Per a cada parell predicció/veritat:
 - Compara directament les etiquetes (pred == gt)
 - Compta com a correcte si coincideixen
 - Si no coincideixen i s'ha demanat detall d'errors:
 - Registra el tipus d'error (gt → pred)
 - Compta la freqüència de cada error

Sortida:

- Sense return_errors: Retorna només el percentatge d'encerts
- Amb return_errors=True: Retorna tupla amb:
 - Percentatge d'encerts
 - Diccionari d'errors format: {(gt_real, pred_errònia): quantitat}

2.2.2.- Get_color_accuracy

Objectiu: Aquesta funció calcula la precisió en la classificació de colors mitjançant la mètrica F1-score, que combina precision i recall en un sol valor. És especialment útil per avaluar models d'etiquetatge de colors com KMeans.

Paràmetres d'Entrada:

- pred_labels: Llista de conjunts d'etiquetes predites (ex: [{'Red','Blue'}, {'Green'}, ...])
- gt_labels: Llista de conjunts d'etiquetes reals (ground truth) en el mateix format

Processament:

1. Validació inicial: Verifica que les llistes d'entrada tinguin la mateixa longitud
2. Càlcul per cada imatge:
3. Determina els veritables positius (tp), falsos positius (fp) i falsos negatius (fn)
4. Calcula precision: $tp / (tp + fp)$
5. Calcula recall: $tp / (tp + fn)$
6. Computa F1-score: $2 * (precision * recall) / (precision + recall)$
7. Gestió de casos especials: Evita errors de divisió per zero

Sortida:

- Retorna el F1-score mitjà en percentatge sobre totes les imatges

2.2.3.- Kmeans_analysis

Objectiu: Aquesta funció realitza una anàlisi exhaustiva de l'algorisme KMeans per a diferents valors de K (de 2 a Kmax) utilitzant diversos mètodes d'inicialització i heurístiques. El procés es divideix en tres parts principals:

Configuració i Execució:

- Prova 5 mètodes d'inicialització: 'first', 'random', 'custom', 'kmeans++' i 'pca'
- Utilitza la heurística WCD (Within-Class Distance) per avaluar els resultats
- Per a cada combinació (mètode d'inicialització + heurística + valor de K):
- Crea i ajusta un model KMeans
- Calcula el valor de l'heurística, temps d'execució i iteracions
- Prediu colors per a cada imatge i calcula l'accuracy


Visualització de Resultats:


- Gràfic 1: Evolució del valor de l'heurística (WCD) en funció de K
- Gràfic 2: Precisió en la predicció de colors per als diferents K
- Gràfic 3: Temps d'execució requerit per a cada configuració

Interpretació dels Resultats:

- L'heurística WCD mostra com la distància intra-cluster varia amb K
- La precisió permet identificar el valor òptim de K per a la classificació de colors
- Els temps d'execució ajuden a avaluar l'eficiència computacional

Exemples de cas d'us:





Mitjanes per mètode d'inicialització:

first: Temps mitjà = 18.77s, Precisió mitjana = 54.76%


random: Temps mitjà = 8.45s, Precisió mitjana = 55.61%


custom: Temps mitjà = 15.39s, Precisió mitjana = 55.70%

kmeans++: Temps mitjà = 10.45s, Precisió mitjana = 55.69%

pca: Temps mitjà = 15.33s, Precisió mitjana = 54.62%

kmeans_analysis pel conjunt imgs_cropped





Mitjanes per mètode d'inicialització:

first: Temps mitjà = 15.62s, Precisió mitjana = 64.32%


random: Temps mitjà = 16.81s, Precisió mitjana = 64.91%



custom: Temps mitjà = 17.55s, Precisió mitjana = 64.21%

kmeans++: Temps mitjà = 13.48s, Precisió mitjana = 64.83%

pca: Temps mitjà = 22.67s, Precisió mitjana = 64.83%

kmeans_analysis pel conjunt test_imgs





Mitjanes per mètode d'inicialització:

first: Temps mitjà = 106.15s, Precisió mitjana = 50.74%

random: Temps mitjà = 58.96s, Precisió mitjana = 50.97%

custom: Temps mitjà = 78.49s, Precisió mitjana = 50.45%

kmeans++: Temps mitjà = 65.35s, Precisió mitjana = 50.75%

pca: Temps mitjà = 102.72s, Precisió mitjana = 50.78%

Conclusions dels Anàlisis Realitzats

A partir dels tres anàlisis realitzats, podem extreure les següents conclusions clau:

- **Comportament de la Distància Intra-Classe (WCD):**

La WCD disminueix a mesura que augmenta K, indicant una major cohesió dins dels clústers. No obstant això, aquesta millora s'estabilitza a partir d'un cert valor de K, demostrant que incrementar més clústers no aporta beneficis significatius.

- **Relació entre K i la Precisió:**

En general, la precisió millora amb valors més alts de K, però pot estancar-se o fins i tot disminuir quan K és massa gran, a causa del sobreajustament (overfitting).

Aquest fenomen és especialment notable en el conjunt test_imgs, on la precisió disminueix a partir de K=6.

- **Rendiment dels Mètodes d'Inicialització:**

El mètode random destaca per la seva velocitat, però la seva precisió decau en valors alts de K (especialment a $K=9$ i $K=10$).

En canvi, altres mètodes com k-means++ o PCA mantenen una precisió més estable, tot i requerir més temps de càlcul.

- **Impacte del Retall d'Imatges (img_cropped):**

Les imatges retallades ofereixen major precisió en la classificació de colors, ja que eliminen el soroll del fons.

No obstant això, el procés és més lent en comparació amb les imatges originals.

- **Diferenciació entre Conjunts de Dades (imgs vs. test_imgs):**

En el conjunt imgs (tant retallades com originals), la precisió creix consistentment amb K.

En canvi, en test_imgs, la precisió disminueix a partir de K=6, possiblement per sobreajustament o manca de generalització.

El temps d'execució en test_imgs és molt superior al de imgs, a causa de la mida més gran del conjunt de dades.

- **Elecció del Valor Òptim de K:**

Per al conjunt test_imgs, el valor ideal de K es troba entre 2 i 5, ja que valors superiors redueixen la precisió i incrementen el cost computacional sense beneficis clars. L'única excepció és la inicialització random, on *K=6* ofereix el millor rendiment.

En canvi, en el conjunt imgs, valors més alts de K (fins a 10) poden ser útils, ja que mantenen una alta precisió sense un increment excessiu en el temps de processament.

2.2.4.- Knn_systematic_analysis

Objectiu: avaluar exhaustivament l'algorisme KNN utilitzant diferents combinacions de paràmetres per determinar la configuració òptima per a la classificació de formes en imatges de roba.

Paràmetres d'entrada:

- Conjunt d'entrenament
- Llista de conjunts d'etiquetes reals (ground truth) en el mateix format
- Conjunt d'imatges
- Llista de conjunts d'etiquetes reals (ground truth) en el mateix format

Processament:

1. Preparació inicial:

- Carrega les dades d'entrenament i test
- Inicialitza estructures per emmagatzemar resultats

2. Bucle d'avaluació:

- Per a cada combinació de paràmetres (k, mètrica, característiques):
 - Entrena el model KNN
 - Realitza prediccions
 - Calcula l'accuracy
 - Emmagatzema els resultat

3. Visualització de resultats:



- Mostra resum detallat ordenat per accuracy
- Calcula i mostra mitjanes agrupades
- Genera gràfics comparatius

Parametres de sortida:

- Per cada k retorna:
 - Mètrica
 - Característiques
 - Precisió

Exemple cas d'ús:

knn_systematic_analysis aplicat al conjunt imgs





Precisión y tiempo medio por combinación de métrica y características:

cosine, raw: 86.98% precisión media | 1.34 s tiempo medio

euclidean, raw: 86.36% precisión media | 0.97 s tiempo medio

manhattan, raw: 85.68% precisión media | 1.19 s tiempo medio

cosine, mean_halves: 64.44% precisión media | 13.43 s tiempo medio

euclidean, mean_halves: 62.90% precisión media | 16.00 s tiempo medio

manhattan, mean_halves: 61.67% precisión media | 11.98 s tiempo medio

euclidean, grayscale_mean: 61.11% precisión media | 10.00 s tiempo medio

manhattan, grayscale_mean: 61.11% precisión media | 7.88 s tiempo medio


cosine, grayscale_mean: 11.11% precisión media | 13.35 s tiempo medio

euclidean, mean_rgb: 61.11% precisión media | 9.52 s tiempo medio


manhattan, mean_rgb: 61.11% precisión media | 8.73 s tiempo medio

cosine, mean_rgb: 11.11% precisión media | 8.99 s tiempo medio

knn_systematic_analysis aplicat al conjunt imgs_cropped





Tiempo de predicción vs K por combinación



 Precisión y tiempo medio por combinación de métrica y características:

manhattan, raw: 21.48% precisión media | 0.08 s tiempo medio
 euclidean, raw: 20.43% precisión media | 0.09 s tiempo medio
 cosine, raw: 18.77% precisión media | 0.12 s tiempo medio
 cosine, mean_halves: 14.88% precisión media | 1.22 s tiempo medio
 euclidean, mean_halves: 12.90% precisión media | 1.25 s tiempo medio
 manhattan, mean_halves: 11.79% precisión media | 1.01 s tiempo medio
 cosine, grayscale_mean: 11.11% precisión media | 1.06 s tiempo medio
 cosine, mean_rgb: 11.11% precisión media | 0.91 s tiempo medio
 euclidean, mean_rgb: 10.80% precisión media | 0.73 s tiempo medio
 euclidean, grayscale_mean: 10.80% precisión media | 0.68 s tiempo medio
 manhattan, mean_rgb: 10.80% precisión media | 0.64 s tiempo medio
 manhattan, grayscale_mean: 10.80% precisión media | 0.63 s tiempo medio

knn_systematic_analysis aplicat a el conjunt test_imgs





Precisi3n y tiempo medio por combinaci3n de m3trica y caracter3sticas:

manhattan, raw: 90.72% precisi3n media | 4.58 s tiempo medio

euclidean, raw: 90.22% precisi3n media | 4.24 s tiempo medio

cosine, raw: 90.16% precisi3n media | 6.82 s tiempo medio

euclidean, mean_halves: 53.31% precisi3n media | 44.26 s tiempo medio

manhattan, mean_halves: 52.76% precisi3n media | 47.38 s tiempo medio

cosine, mean_halves: 41.13% precisi3n media | 72.47 s tiempo medio

manhattan, grayscale_mean: 32.52% precisi3n media | 36.26 s tiempo medio

euclidean, mean_rgb: 32.52% precisi3n media | 31.98 s tiempo medio

manhattan, mean_rgb: 32.52% precisi3n media | 27.48 s tiempo medio

euclidean, grayscale_mean: 32.52% precisi3n media | 26.36 s tiempo medio

cosine, mean_rgb: 10.58% precisi3n media | 58.09 s tiempo medio

cosine, grayscale_mean: 10.58% precisi3n media | 48.25 s tiempo medio

Anàlisi dels resultats del KNN:

Els resultats obtinguts demostren de manera concloent que la selecci3n de paràmetres en l'algorisme KNN és determinant per al seu rendiment. La configuraci3n òptima identifica $K=2$ amb caracter3stiques RAW i mètrica euclidiana o Manhattan com la més eficient, assolint una precisi3n del 100% amb temps d'execuci3n inferiors al segon. Aquesta combinaci3n optimitza tant la precisi3n com la velocitat, convertint-la en la opci3n ideal per a aplicacions reals.

S'observa un patró clar: a mesura que augmenta el valor de K , la precisi3n disminueix significativament. Aquest fenomen s'explica per la incorporaci3n de veïns més allunyats, que introdueixen soroll i dilueixen els patrons locals rellevants. La diferència és notable, amb una caiguda de precisi3n del 100% ($K=2$) al 80% ($K=10$), sense que aquest increment en K aporti millores en velocitat o altres mètriques.

Pel que fa a les combinacions menys efectives, les caracter3stiques mean_rgb o grayscale_mean juntament amb la mètrica cosinus presenten un rendiment excepcionalment baix (11.11% de precisi3n) i temps d'execuci3n elevats. El més rellevant és que aquestes configuracions mantenen una precisi3n consistentment baixa independentment del valor de K , demostrant que algunes combinacions de paràmetres poden invalidar completament la utilitat de l'algorisme.

En canvi, les caracter3stiques RAW mostren un comportament robust i consistent amb totes les mètriques avaluades, especialment amb valors baixos de K . Aquesta fiabilitat, combinada amb uns temps d'execuci3n mínims, les converteix en l'opci3n més adequada per a la implementaci3n pràctica del KNN en problemes de classificaci3n d'imatges.

- **Impacte del retall d'imatges:**

Els resultats amb `img_cropped` confirmen que l'ús del KNN amb imatges retallades no és recomanable, ja que la pèrdua d'informació espacial redueix dràsticament la fiabilitat del model, tot i que els temps de processament siguin més ràpids.

- **Anàlisi del conjunt `test_imgs`:**

En l'avaluació final amb `test_imgs`, les línies del gràfic mostren un comportament estable. Les tres configuracions amb característiques RAW destaquen per mantenir una precisió consistentment superior al 90%. En canvi, la mètrica cosinus, excepte quan s'utilitza amb característiques RAW, es manté al voltant del 10% de precisió. Pel que fa als temps d'execució, aquests es mantenen uniformes, amb una única excepció: una picada significativa entre $K=7$ i $K=9$.

- **Conclusió final:**

Aquest estudi posa en relleu la importància crítica d'una selecció acurada dels paràmetres en l'algorisme KNN. Mentre que les combinacions adequades poden oferir resultats excel·lents, les eleccions incorrectes poden conduir a resultats completament insatisfactoris. La clau de l'èxit rau en la simplicitat: valors baixos de K , característiques RAW i mètriques tradicionals ofereixen el millor equilibri entre precisió, velocitat i fiabilitat, consolidant-se com l'opció òptima per a aplicacions pràctiques.

2.2.5.- `Compare_find_bestK_heuristics`

Objectiu: avaluar diferents heurístiques per determinar el nombre òptim de clústers (K) en l'algorisme K-Means. Aquesta implementació permet comparar quatre mètodes diferents:

- **WCD (Within-Class Distance):** Minimitza la distància intra-cluster
- **BCD (Between-Class Distance):** Maximitza la distància inter-cluster
- **Fisher:** Maximitza la relació BCD/WCD
- **Elbow Method:** Identifica el punt de rendiment decreixent

Paràmetres d'entrada:

- Conjunt d'imatges
- K màxima (predeterminadament $max_K = 10$)
- Llista de conjunts d'etiquetes reals (ground truth) en el mateix format

Processament:

1. Preparació de dades:

- Converteix les imatges en una matriu de píxels (X)
- Inicialitza l'estructura per emmagatzemar resultats

2. Cerca del millor K:


- Per cada heurística:
 - i. Cronometra el temps d'execució
 - ii. Troba el K òptim utilitzant find_bestK
 - iii. Executa K-Means amb el K trobat
 - iv. Calcula l'accuracy de predicció de colors

3. Visualització:

- Genera gràfics comparatius
- Mostra un resum detallat dels resultats

Exemple cas d'ús:

Aplicant compare_find_bestK_heuristics al conjunt d'imatges obtenim:



- WCD : K = 4, Accuracy = 53.96%
- BCD : K = 10, Accuracy = 56.41%
- FISHER : K = 10, Accuracy = 56.41%
- ELBOW : K = 4, Accuracy = 53.96%

Anàlisi dels resultats del Compare_find_bestK_heuristics:

El mètode WCD (Within-Class Distance) i l'Elbow Method identifiquen $K=4$ com a valor òptim, amb una precisió del 53.96% en ambdós casos. Això indica que aquestes heurístiques tendeixen a seleccionar un nombre més reduït de clústers, oferint una solució equilibrada entre simplicitat i rendiment. La seva eficiència els fa especialment adequats per a anàlisis ràpides o quan es treballa amb recursos limitats.

D'altra banda, les heurístiques BCD (Between-Class Distance) i Fisher recomanen $K=10$, assolint una precisió lleugerament superior del 56.41%. Aquests resultats mostren que, tot i requerir un major nombre de clústers, aquests mètodes poden capturar millor l'estructura complexa de les dades, especialment quan la separació entre grups és una prioritat. No obstant això, l'increment de precisió és només del 2.45%, el que pot no justificar la major complexitat en molts escenaris pràctics.

En resum, l'elecció de l'heurística depèn dels objectius de l'anàlisi: eficiència i simplicitat (WCD/Elbow) o màxima separació entre grups (BCD/Fisher), amb una diferència de precisió relativament petita entre ambdues aproximacions.

3.- Millores sobre Kmeans i KNN


3.1.- Millores implementades a KMeans


(a) Inicialitzacions Afegides

Hem implementat 2 mètodes d'inicialització addicionals als existents:

- **K-means++**: Selecciona punts inicials amb probabilitat proporcional a la distància als centroides existents
- **PCA**: Ubica centroides al llarg de la primera component principal

Aplicant kmeans_analysis al conjunt d'imatges cropped obtenim:





Mitjanes per mètode d'inicialització:

first: Temps mitjà = 15.62s, Precisió mitjana = 64.32%

random: Temps mitjà = 16.81s, Precisió mitjana = 64.91%

custom: Temps mitjà = 17.55s, Precisió mitjana = 64.21%

kmeans++: Temps mitjà = 13.48s, Precisió mitjana = 64.83%

pca: Temps mitjà = 22.67s, Precisió mitjana = 64.83%

Anàlisi dels resultats del Kmeans:

k-means++ destaca com el mètode més ràpid, amb un temps mitjà d'execució de 13.48 segons de mitjana, superant significativament altres mètodes com PCA, que és el més lent amb 22.67 segons de mitjana. Això indica que k-means++ és una opció eficient per a conjunts de dades grans o aplicacions que requereixen baixa latència.

Per altra banda, PCA aconsegueix la màxima precisió (68.36%) per a valors alts de K (K=10), tot i ser el mètode més lent. Això suggereix que PCA és ideal per a tasques que prioritzen l'exactitud sobre el temps d'execució, especialment en configuracions amb més clústers.

Finalment, podem concloure amb que si volem prioritzar la velocitat, utilitzarem k-means++ pel seu equilibri òptim entre temps i precisió. Mentre que, per màxima precisió usarem PCA especialment per a $K \geq 8$.

(b) Heurístiques per a Determinar K Òptim

S'han implementat 3 noves heurístiques a `find_bestK`:

- BCD (Between-Class Distance): Maximitza la distància entre clusters
- Fisher Score: Maximitza la relació entre distància inter-cluster i intra-cluster
- Elbow Method: Identifica el punt de rendiment decreixent en WCD

Aquestes implementacions les podem veure a l'anàlisi `compare find bestK heuristics` on tenim aquestes dades:

3.2.- Millores implementades a KNN

a) Mètriques de distància afegides

- **Distància Manhattan**
 - **Avantatges:** Menys sensible a valors atípics que l'euclidiana, millor rendiment en espais d'alta dimensió.
- **Distància Cosinus**
 - **Avantatges:** Eficaz per comparar orientació més que magnitud, útil quan la mida de la imatge no és rellevant.

b) Mètodes d'extracció de característiques

- **Mean RGB:** Calcula el valor mitjà de cada canal RGB per separat.
 - **Dimensionalitat:** 3 característiques (R, G, B)
 - **Avantatge:** Redueix dràsticament la dimensionalitat mantenint informació de color.
- **Mean Halves:** Divideix la imatge en meitats superior i inferior i calcula la mitjana de cada meitat.
 - **Dimensionalitat:** 2×canals (6 per RGB, 2 per escala de grisos)
 - **Avantatge:** Captura informació espacial bàsica amb molt baixa dimensionalitat.
- **Grayscale Mean**
 - **Descripció:** Calcula el valor mitjà de tota la imatge en escala de grisos.
 - **Dimensionalitat:** 1 característica
 - **Avantatge:** Màxima reducció dimensional, encara que amb pèrdua significativa d'informació.

Aquestes noves implementacions ja han estat estudiades a l'estudi de KNN fet anteriorment

4.- Altres implementacions

4.1.- Visualitzar Retrieval Amb KMeans

Objectiu: Aquesta funció permet visualitzar els resultats de les cerques (retrieval) realitzades amb K-Means, sigui per color, forma o combinats. Mostra les imatges recuperades ordenades segons la rellevància i inclou informació addicional com percentatges de color o confiança en la predicció.

Paràmetres d'Entrada:

- test_imgs: Llista d'imatges a visualitzar.
- predicted_shapes: Etiquetes de forma predites pel KNN (opcional).
- color_preds: Etiquetes de color predites per K-Means (opcional).
- color_percentages: Percentatges de colors per imatge (opcional).
- shape_votes: Confiança en la predicció de forma (opcional).
- query_shape i query_colors: Forma i colors a cercar.
- color, forma, ambos: Flags per activar cerques per color, forma o combinades.
- n: Nombre d'imatges a mostrar.

Processament:

1. Filtra les imatges segons els criteris de cerca (color, forma o combinats).
2. Ordena els resultats segons la rellevància (percentatge de color o confiança en la forma).
3. Mostra les imatges amb informació addicional (percentatges o confiança) i destaca els encerts/errors si es disposa de ground truth.

4.2.- Mostrar_retrieval

Objectiu: Funció auxiliar que mostra les imatges recuperades en una graella, juntament amb informació com percentatges de color o confiança en la predicció.

Paràmetres d'Entrada:

- retrieved_with_scores: Llista de tuples (imatge, score).
- n: Nombre d'imatges a mostrar.
- title: Títol de la visualització.
- ok: Llista que indica si les prediccions són correctes (opcional).

Processament:

1. Selecciona les n imatges més rellevants.
2. Mostra les imatges en una graella amb el score associat.
3. Destaca les imatges correctes/incorrectes si es proporciona el paràmetre ok.

4.3.- Resize_images

Objectiu: Redimensiona un conjunt d'imatges a una mida específica per estandarditzar-les per als algorismes. És especialment útil a l'hora de fer la cerca d'imatges retallades

Paràmetres d'Entrada:

- images: Llista d'imatges.
- target_shape: Mida objectiva (amplada, alçada, canals).

Processament:

1. Utilitza la llibreria PIL per redimensionar cada imatge.
2. Retorna un array de numpy amb les imatges redimensionades.

4.4.- Kmeans interactiu

Objectiu: Interfície interactiva per executar K-Means amb diferents configuracions (inicialització, heurística, valor de K) i visualitzar els resultats.

Funcionament:

1. Permet triar entre imatges originals o retallades.
2. Ofereix opcions per seleccionar mètodes d'inicialització (kmeans++, PCA, etc.) i heurístiques (WCD, BCD, etc.).
3. Calcula automàticament el millor K o permet introduir-lo manualment.
4. Mostra els resultats de cerca per color i visualitza els clústers generats.

Exemple de cas d'ús:

```
=== SELECCIÓN DE TIPO DE IMÁGENES PARA KMEANS===  
1. Usar imágenes originales  
2. Usar imágenes recortadas (cropped)  
3. Salir  
Selecciona una opción (1-3):
```

```
Selecciona el método de inicialización:  
1. first  
2. random  
3. custom  
4. kmeans++  
5. pca  
6. salir  
Selecciona (1-6):
```

```
Selecciona el método de evaluación:  
1. WCD  
2. BCD  
3. Fisher  
4. salir  
Selecciona (1-4): 3  
✅ Has seleccionado: Fisher  
  
¿Quieres introducir K manualmente (1) o usar buscar la mejor k (2)? (1/2): 2  
🔍 Buscando mejor K para Fisher...  
✅ Datos preparados (X reducido)  
⚙️ K automático seleccionado: 10  
  
🧠 Procesando imágenes con KMeans (K=10, kmeans++, Fisher)...  
  
📊 Precisión de predicción de colores: 57.05%  
  
¿Quieres hacer una búsqueda por color? (s/n):
```

¿Quieres buscar otros colores? (s/n): s

Colores disponibles:

1. Red
2. Orange
3. Yellow
4. Green
5. Blue
6. Purple
7. Pink
8. Brown
9. Black
10. White
11. Grey
0. Salir

Introduce los números de los colores separados por comas (ej: 1,3,5): 8

🔍 Recuperando imágenes con colores: Brown

🔍 Visualización de recuperación avanzada...

→ Recuperando solo por color...

Imatges recuperades: 46

Color: Brown

30.3%



25.6%



20.0%



15.3%



14.8%



13.3%



8.2%



7.5%



```
¿Quieres visualizar el K-means para imágenes representativas con Brown? (s/n): s
```

```
🖼️ Mostrando K-means para imágenes representativas con Brown:
```

```
Imagen 104 - Porcentaje de Brown: 11.4%  
<Figure size 640x480 with 0 Axes>
```

```
Imagen 100 - Porcentaje de Brown: 1.9%  
<Figure size 640x480 with 0 Axes>
```

```
Imagen 15 - Porcentaje de Brown: 0.6%  
<Figure size 640x480 with 0 Axes>
```

```
¿Quieres buscar otros colores? (s/n):
```



4.5.- KNN interactiu

Objectiu: Interfície interactiva per executar KNN amb configuracions personalitzables (mètrica de distància, tipus de característiques, valor de k).

Funcionament:

1. Permet triar entre imatges originals o retallades.
2. Configuració de paràmetres com k, mètrica (euclidiana, Manhattan, cosinus) i tipus de característiques (raw, mean_rgb, etc.).
3. Mostra la precisió de classificació i els errors més freqüents.
4. Inclou cerques interactives per forma.

Exemple de cas d'ús:

=== SELECCIÓN DE TIPO DE IMÁGENES PARA KNN ===

1. Usar imágenes originales
2. Usar imágenes recortadas (cropped)
3. Salir

Selecciona una opción (1-3): 1

✅ Usando imágenes originales.

🖼️ Total imágenes cargadas:

- Entrenamiento: 2328
- Test: 180
- Total: 2508

Introduce el valor de k (2-10): 2

Selecciona la métrica de distancia:

1. euclidean
2. manhattan
3. cosine
4. salir

Selecciona (1-4): 3

Selecciona el tipo de característica:

1. raw
2. mean_rgb
3. mean_halves
4. grayscale_mean
5. salir

Selecciona (1-5): 4

🧠 Clasificando imágenes con KNN...

🎯 Precisión de clasificación: 100.00%

✅ No se encontraron errores.

¿Quieres hacer una búsqueda por forma? (s/n): s

Selecciona la forma que quieres buscar:

1. Dresses
2. Flip Flops
3. Jeans
4. Sandals
5. Shirts
6. Shorts
7. Socks
8. Handbags
9. Heels
- q. salir

Escribe el número correspondiente (1-9): 7

🔍 Recuperando imágenes con forma: Socks...

🔍 Visualización de recuperación avanzada...

→ Recuperando solo por forma...

Imatges recuperades: 20

¿Quieres buscar otras formas? (s/n): |

Forma: Socks

100.0%



100.0%



100.0%



100.0%



100.0%



100.0%



100.0%



100.0%



4.6.- Buscador interactiu

Objectiu: Interfície unificada per realitzar cerques combinades (color + forma) amb opcions avançades de configuració per als algorismes K-Means i KNN.

Funcionament:

1. Permet triar entre imatges originals o retallades.
2. Suporta cerques per color, forma o combinades.
3. Inclou opcions avançades com selecció d'heurístiques i mètriques.
4. Mostra els resultats ordenats per rellevància.

```
¿Quieres usar imágenes recortadas (cropped)? (s/n): n

Selecciona tipo de búsqueda:
1. Por color
2. Por forma
3. Por ambos (color + forma)
Opción (1-3): 3

Colores disponibles:
1. Red
2. Orange
3. Yellow
4. Green
5. Blue
6. Purple
7. Pink
8. Brown
9. Black
10. White
11. Grey
Introduce los números de los colores separados por comas (ej: 1,3,5): 9
```

Formas disponibles:

1. Dresses
2. Flip Flops
3. Jeans
4. Sandals
5. Shirts
6. Shorts
7. Socks
8. Handbags
9. Heels

Selecciona una forma (1-9): 5

¿Quieres usar configuración avanzada? (s/n): n

🔍 Ejecutando KMeans por defecto con find_bestK (WCD)...

✅ K detectado automáticamente: 4

🧠 Ejecutando KNN con k=4 por defecto...

🔍 Visualización de recuperación avanzada...

→ Recuperando por forma + color...

Imatges recuperades: 5

Shirts + Black

56.4%



53.5%



53.4%



53.2%



Flux Alternatiu:

¿Quieres usar configuración avanzada? (s/n): s

Selecciona el método de inicialización para KMeans:

1. first
2. random
3. custom
4. kmeans++
5. pca

Opción (1-5): 4

Selecciona el método de evaluación para KMeans:

1. WCD
2. BCD
3. Fisher

Opción (1-3): 1

¿Quieres introducir K manualmente (1) o usar búsqueda automática (2)? (1/2): 1

Introduce el valor de K (2-10): 2



Ejecutando KNN con k=2...

Selecciona métrica de distancia para KNN:

1. euclidean
2. manhattan
3. cosine

Opción (1-4): 1

Selecciona tipo de característica:

1. raw
2. mean_rgb
3. mean_halves
4. grayscale_mean

Opción (1-4): 1



Visualización de recuperación avanzada...

→ Recuperando por forma + color...

Imatges recuperades: 1

Shirts + Black

70.0%



4.7.- Menú Principal (main)

Objectiu: El menú principal és el punt d'entrada de l'aplicació i permet als usuaris interactuar amb totes les funcionalitats implementades de manera organitzada i intuïtiva. Aquest menú ofereix accés a les diferents opcions del sistema, des d'anàlisi sistemàtica fins a eines interactives.

Funcionament:

El menú es mostra en un bucle infinit fins que l'usuari tria sortir. Les opcions disponibles són:

1. Executar KMeans sistemàtic (anàlisi completa):
 - Permet avaluar K-Means amb diferents configuracions (valors de K, mètodes d'inicialització, heurístiques) tant per a imatges originals com retallades.
 - Inclou opcions per triar entre el dataset estès o el conjunt de test.
2. Executar KNN sistemàtic (anàlisi completa):
 - Realitza una avaluació exhaustiva del KNN amb diferents combinacions de paràmetres (k, mètriques de distància, tipus de característiques).
 - Compara resultats amb/sense retall d'imatges.
3. Executar KMeans interactiu:
 - Obre la interfície interactiva de K-Means per a experiments personalitzats.
 - Permet seleccionar imatges originals o retallades i ajustar paràmetres com la inicialització o l'heurística.
4. Executar KNN interactiu:
 - Obre la interfície interactiva de KNN per a classificació de formes.
 - Inclou cerques per forma i visualització d'errors.
5. Buscador interactiu:
 - Permet fer cerques combinades (color + forma) amb opcions avançades.
 - Inclou suport per a imatges retallades i configuracions personalitzades.
6. Visualitzar imatges del dataset:
 - Mostra mostres aleatòries del dataset estès o del conjunt de test per a una revisió ràpida.
7. Comparació de mètodes find_bestK:
 - Avalua diferents heurístiques (WCD, BCD, Fisher, elbow) per determinar el K òptim en K-Means.

8. Sortir:
 - Finalitza l'execució del programa.

Connexió amb la resta del sistema:

El menú principal actua com a pont entre l'usuari i les funcions descrites als apartats 4.1–4.5, coordinant-ne l'execució i garantint una experiència coherent. Cada opció crida a les funcions subjacents amb els paràmetres adequats, segons les preferències de l'usuari (per exemple, triar entre imatges cropped o no).

Aquesta estructura modular facilita tant el desenvolupament com l'ús de l'aplicació, cosa que permet afegir noves funcionalitats sense modificar la lògica principal.

Exemple de cas d'ús

```
=== MENÚ PRINCIPAL ===
1. Ejecutar KMeans sistemático (análisis completo)
2. Ejecutar KNN sistemático (análisis completo)
3. Ejecutar KMeans interactivo
4. Ejecutar KNN interactivo
5. Buscador
6. Visualizar imágenes del dataset
7. Comparación de metodos find_bestK
8. Salir

Selecciona una opción (1-8):
```

Abans de les anàlisis es mostra aquest missatge d'avís

```
=== ANÁLISIS SISTEMÁTICO KMEANS ===
⚠ ADVERTENCIA: Este proceso puede tardar varios minutos
Analizará múltiples configuraciones para K de 2 a 10
¿Continuar? (s/n):
```

```
=== ANÁLISIS SISTEMÁTICO KNN ===
⚠ ADVERTENCIA: Este proceso puede tardar varios minutos
¿Continuar? (s/n):
```

Abans de totes les opcions es demana escollir amb quin dataset es treballarà

```
=== KMEANS INTERACTIVO ===  
1. Usar dataset extendido (imgs)  
2. Usar conjunto de test (test_imgs)  
Selecciona (1-2):
```

Opció 6 Visualitzar el dataset

```
Selecciona una opción (1-8): 6  
  
=== VISUALIZACIÓN DEL DATASET ===  
1. Visualizar dataset extendido (imgs)  
2. Visualizar conjunto de test (test_imgs)  
Selecciona (1-2): 1  
  
Total de imagenes a mostrar: 20  
  
Total imágenes extendidas: 180
```



5.- Conclusió global

Al llarg d'aquest projecte hem explorat dues tècniques d'intel·ligència artificial per a l'etiquetatge automàtic de peces de roba: l'aprenentatge supervisat amb KNN per a la classificació de formes, i l'aprenentatge no supervisat amb K-means per a l'extracció de colors predominants.

L'algorisme KNN ha demostrat una elevada precisió quan s'utilitzen característiques de tipus raw combinades amb distàncies euclidianes o Manhattan. En concret, amb $k = 2$ i característiques raw, s'ha arribat a una precisió perfecta del 100% en la classificació de formes amb el conjunt de dades extenses i de més del 90% en el conjunt de test. Aquest resultat indica que representacions simples, però informatives poden ser molt efectives. No obstant, quan es retallen les imatges, el rendiment de KNN empitjora considerablement, ja que es perden parts essencials de la forma, cosa que dificulta la classificació correcta.

Pel que fa a K-means, l'anàlisi quantitatiu ha permès identificar les configuracions òptimes per a l'extracció de colors. Les imatges retallades han ofert millors resultats, amb una precisió mitjana del 64.91% amb inicialització random. Els millors mètodes d'inicialització han estat k-means++ (pel seu bon equilibri entre temps i precisió) i PCA (per a precisió màxima en valors alts de K). També hem comparat heurístiques com WCD, BCD, Fisher i l'Elbow method per trobar el valor òptim de K, concloent que la millor elecció depèn del balanç entre simplicitat i separació entre grups.

Les cerques combinades de color i forma han posat de manifest que la combinació de dos algorismes pot ser molt potent, però també que cal escollir bé les dades d'entrada. Concretament, hem vist que mentre que el retall és beneficiós per al color, pot empitjorar la identificació de la forma.

Basant-nos en els resultats, proposem les següents recomanacions per a aplicacions reals:

Per a classificació de formes (KNN):

- Utilitzar $k=2$ amb característiques raw i distància euclidiana/manhattan (precisió >90%)
- Evitar imatges retallades si la forma és prioritària.

Per a extracció de colors (K-Means):

- Preferir inicialització k-means++ (equilibri velocitat-precisió) o PCA (màxima precisió amb $K \geq 8$).
- Sempre que sigui possible, retallar imatges per eliminar soroll del fons.

Per a cerques combinades:

- Utilitzar imatges originals per preservar informació de forma, fins i tot a canvi de menor precisió en color.

En definitiva, aquest projecte ens ha permès entendre millor les fortaleeses i limitacions de tècniques senzilles d'aprenentatge automàtic. També hem comprovat que la tria dels paràmetres i el tipus de dades (retallades o no) tenen un impacte directe en el rendiment i construir un programa on poder testear diferents tipus d'inicialitzacions i càlculs són molt importants per a maximitzar l'eficiència veient els resultats. Aquest coneixement pot ser útil en futurs projectes més complexos que combinin etiquetatge supervisat i no supervisat.